

Métodos Quantitativos



Prof. Júlio Cesar Nievola

PPG1a – PUCPR

Estatística Sumária

- ▶ Estatística Sumária são números que resumem as propriedades dos dados.
- ▶ Propriedades sumarizadas incluem frequência, posição e dispersão:
 - ▶ Exemplos: posição – média;
dispersão – desvio padrão.
- ▶ A maioria das estatísticas sumárias pode ser calculada em um único passo através dos dados.



Frequência e Moda

- A frequência do valor de um atributo é a percentagem do tempo em que o valor ocorre no conjunto de dados.
- Por exemplo, dado o atributo 'gênero' e uma população representativa de pessoas, o gênero 'feminino' ocorre cerca de 50% do tempo.
- A moda de um atributo é o valor mais frequente do atributo.
- As noções de frequência e moda são usadas tipicamente com dados categóricos.



Medidas de tendência central

- Com grandes amostras, a observação dos dados não permite determinar as características relevantes.
- Medidas de tendência central:
 - Medidas de ordenamento;
 - Medidas de posição;
 - Medidas de dispersão.

Medidas de ordenamento

- Permitem determinar a posição de um certo elemento em relação aos demais elementos da amostra.
- Um ganho de 6% ao ano em uma aplicação financeira é maior ou menor que o ganho em outras aplicações financeiras?

Amostra	Amostra Ordenada	Ordem
27	26	1
32	27	2
64	29	3
65	29	4
58	30	5
62	31	6
59	32	7
54	32	8
29	35	9
30	36	10
26	37	11
48	37	12
47	38	13
46	42	14
43	43	15
38	43	16
29	45	17
32	46	18
35	47	19
37	48	20
31	54	21
43	58	22
45	59	23
42	62	24
37	64	25
36	65	26

Medidas de ordenamento – percentil

- O percentil k de uma amostra ($0\% \leq k \leq 100\%$) indica o valor que divide o conjunto de dados em duas partes, uma menor que o argumento k e a outra maior que k .
- A relação entre a escala de 0% a 100% e a série de números naturais 0, 1, 2, ..., n que representa uma série de dados de uma amostra ordenada, o primeiro dado da amostra representa o percentil 0% e o último dado da amostra representa o percentil 100%.

Amostra
27
32
64
65
58
62
59
54
29
30
26
48
47
46
43
38
29
32
35
37
31
43
45
42
37
36

Ponto	Amostra	Ordem	Porcentagem
4	65	1	100,00%
3	64	2	96,00%
6	62	3	92,00%
7	59	4	88,00%
5	58	5	84,00%
8	54	6	80,00%
12	48	7	76,00%
13	47	8	72,00%
14	46	9	68,00%
23	45	10	64,00%
15	43	11	56,00%
22	43	11	56,00%
24	42	13	52,00%
16	38	14	48,00%
20	37	15	40,00%
25	37	15	40,00%
26	36	17	36,00%
19	35	18	32,00%
2	32	19	24,00%
18	32	19	24,00%
21	31	21	20,00%
10	30	22	16,00%
9	29	23	8,00%
17	29	23	8,00%
1	27	25	4,00%
11	26	26	0,00%



Medidas de ordenamento – quartil

- Além do percentil (a cada 1%) há outras formas de definir referências fixas:
 - A cada 10%, chamado de decil;
 - A cada 12,5%, chamado de octil;
 - A cada 25%, chamado de quartil.

Medida de tendência central – mediana

- Coincide com o percentil 50% (ou segundo quartil).
- Após ordenar os n valores, a mediana é calculada:
 - Se n for ímpar, a mediana será o valor da variável na posição $(n+1)/2$;
 - Se n for par, a mediana será igual ao resultado da divisão por dois da soma dos valores das posições $[(n/2)]$ e $[(n/2)+1]$, podendo não ser um valor da variável.

Amostra			
31		Mediana	31,00
38			
19			
27			
24			
42			
32			
18			
43			
15			
39			

Amostra			
27		Mediana	40,00
32			
64			
65			
58			
62			
59			
54			
29			
30			
26			
48			
47			
46			
43			
38			
29			
32			
35			
37			
31			
43			
45			
42			
37			
36			

Medida de tendência central – moda

- Moda é o valor da amostra que mais se repete, ou seja, o valor que tem maior frequência.

Amostra			
14	14	14	13
12	14	15	15
13	15	13	16
11	17	12	12
12	14	14	12
13	11	13	
16	13	14	
Moda	14,00		

Amostra			
27	54	43	43
32	29	38	45
64	30	29	42
65	26	32	37
58	48	35	36
62	47	37	
59	46	31	
Moda	32,00		

Medida de tendência central – média

- A média é o resultado da divisão da soma dos valores das observações ou dados da amostra pela quantidade de dados n .

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Amostra				
31				
38				
19				
27				
24				
42				
32				
18				
43				
15				
39	Média	29,82		

$$\bar{X} = \frac{\sum_{i=1}^{11} X_i}{11} = \frac{31 + 38 + \dots + 39}{11} = 29,82$$

Propriedades da média

- ▶ A soma dos desvios de uma amostra é sempre igual a zero:

$$\sum_{i=1}^n (X_i - \bar{X}) = 0$$

- ▶ A soma dos quadrados dos desvios em relação à própria média de uma variável é sempre igual a um valor mínimo:

$$\sum_{i=1}^n (X_i - \bar{X})^2 \Rightarrow \textit{mínimo}$$

Características da moda

Vantagens	Desvantagens
Fácil de calcular.	Pode estar afastada do centro dos dados.
Não é afetada pelos dados dos extremos da amostra.	Difícil de incluir em funções matemáticas.
Pode ser aplicada em qualquer escala: nominal, ordinal, intervalar e proporcional.	Não utiliza todos os dados da amostra.
	A amostra pode ter mais de uma moda.
	Algumas amostras podem não ter moda.

Características da mediana



Vantagens	Desvantagens
Fácil de calcular.	Difícil de incluir em funções matemáticas.
Não é afeta pelos dados extremos da amostra.	Não utiliza todos os dados da amostra.
É um valor único.	
Pode ser aplicada nas escalas: ordinal, intervalar e proporcional.	

Características da média

Vantagens	Desvantagens
Fácil de compreender e aplicar.	É afetada pelos dados extremos da amostra.
Utiliza todos os dados da amostra.	É necessário conhecer todos os dados da amostra.
É um valor único.	
Fácil de incluir em funções matemáticas.	
Pode ser aplicada nas escalas: intervalar e proporcional.	

Relação entre moda, mediana e média

- Para uma distribuição simétrica, os três valores são iguais;
- Se os dados tem distribuição para a direita (ou positiva), a moda representa o pico e a mediana (dividindo a distribuição em duas áreas iguais) está a sua direita e tem-se a relação:
 - $Média > Mediana > Moda$ (embora nem sempre haja moda)
- Se os dados tem distribuição para a esquerda (ou negativa), a moda representa o pico e a mediana (dividindo a distribuição em duas áreas iguais) está a sua esquerda e tem-se a relação:
 - $Média < Mediana < Moda$ (embora nem sempre haja moda)



Medida de dispersão – desvio absoluto médio

- O uso da soma dos desvios não é adequado pois devido à primeira propriedade da média ele sempre resulta em zero.
- O desvio absoluto médio (DAM) evita isto:

$$DAM = \frac{1}{n} \sum_{i=1}^n |X_i - \bar{X}|$$

Amostra	Desvio	Desvio Absoluto	Resultados	
31	1,18	1,18		
38	8,18	8,18		
19	-10,82	10,82	Média	29,82
27	-2,82	2,82	Soma dos Desvios Absolutos	92,18
24	-5,82	5,82	DAM	8,38
42	12,18	12,18		
32	2,18	2,18	Função DESV.MÉDIO	8,38
18	-11,82	11,82		
43	13,18	13,18		
15	-14,82	14,82		
39	9,18	9,18		

Medida de dispersão – variância

- A variância σ_X^2 da variável X de uma população contendo N dados é dada por:

$$\sigma_X^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu_X)^2$$

- A variância S_X^2 da variável X de uma amostra contendo N dados é calculada através de:

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Medida de dispersão – desvio padrão

- ▶ O desvio padrão da variável X é a raiz quadrada positiva de sua variância. Portanto:
 - ▶ O desvio padrão considerado como população é:

$$\sigma_x = +\sqrt{\sigma_X^2}$$

- ▶ O desvio padrão considerado como amostra é:

$$s_X = +\sqrt{s_X^2}$$

Teorema de Chebyshev

- Para qualquer conjunto de dados de uma amostra ou população, a proporção mínima de valores que se encontram dentro de k desvios padrão ao redor da média é pelo menos igual a $1 - \frac{1}{k^2}$, sendo k uma constante maior que 1

Em uma distribuição simétrica em forma de sino, a porcentagem de dados contidos no intervalo de um desvio padrão ao redor da média é de 68%. Para uma distribuição assimétrica com acentuada inclinação para um lado, essa porcentagem se aproxima de 90%

- ▶ Em uma distribuição simétrica em forma de sino, a porcentagem de dados contidos no intervalo de dois desvios padrão ao redor da média é de 95%. Para uma distribuição assimétrica com acentuada inclinação para um lado, essa porcentagem se aproxima de 100%
- ▶ Para todas as distribuições, a porcentagem de dados contidos no intervalo de três desvios padrão ao redor da média é próximo de 100%

Regra prática - Chebyshev