

Métodos Quantitativos

Prof. Júlio Cesar Nievola

PPGIa – PUCPR

Regressão – 1

- Em estatística, regressão é uma técnica que permite quantificar e inferir a relação de uma variável dependente com variáveis independentes. A análise da regressão pode ser usada como um método descritivo da análise de dados (por exemplo, o ajustamento de curvas).
- Variável dependente = variável resposta ou desejada.
- Variáveis independentes = variáveis explicativas.

Regressão – 2

- A **Regressão** é usada para entender e quantificar a relação entre duas ou mais variáveis.
- Regressões variam de modelos simples a equações altamente complexas.
- Dois usos comuns para a **regressão** são previsão e otimização.
- Quando se trabalha com uma única variável independente (geralmente a mais importante) sobre uma variável dependente, tem-se a **regressão** simples.
- Quando se considera os efeitos de duas ou mais variáveis independentes sobre uma variável dependente, utiliza-se a análise de **regressão** múltipla.

Tipos de Regressão


- Tipos de Regressão
 - Regressão Linear
 - Regressão Polinomial
 - Regressão Logística
 - Regressão Quantílica
 - Regressão Ridge
 - Regressão Lasso
 - Regressão ElasticNet
 - Regressão de Componentes Principais
 - ...

Problemas que podem ocorrer com a Regressão

- ***Multicolinearidade:*** Indica que as variáveis independentes são altamente correlacionadas entre si. Muitos tipos de técnicas de regressão pressupõem que a multicolinearidade não deve estar presente no conjunto de dados, pois ela causa problemas na classificação de variáveis com base em sua importância, ou dificulta o trabalho na seleção da variável independente mais importante.
- ***Heterocedasticidade:*** Ela se apresenta como uma forte dispersão dos dados em torno de uma reta, indicando que a variabilidade da variável dependente não é igual entre os valores de uma variável independente. Por exemplo, a medida que a renda aumenta, a variabilidade do consumo de alimentos aumenta. Uma pessoa mais pobre gastará uma quantia bastante constante comendo sempre comida barata; uma pessoa mais rica pode, ocasionalmente, comprar comida barata e, outras vezes, comer refeições caras. Aqueles com maiores rendimentos apresentam uma maior variabilidade de consumo de alimentos.

Sub- e Sobre-ajuste




- Quando usamos variáveis explicativas desnecessárias, isso pode levar ao sobre-ajuste (“overfitting” em inglês), que significa que nosso modelo funciona bem no nos dados atuais mas não consegue ter um bom desempenho nas situações futuras. Sobre-ajuste também é conhecido como problema de **alta variância**.
- Quando nosso algoritmo funciona tão mal que é incapaz de modelar os dados atuais então dizemos que ele não serve para os dados. Isto também é conhecido como problema de **alto viés** (“bias” em inglês).
- Nas figuras abaixo podemos ver que ajustar uma regressão linear (a primeira figura) não iria ajustar bem os dados, ou seja, levaria a grandes erros mesmo nos dados atuais. Usar um ajuste polinomial (como acontece na segunda figura) é mais balanceado, isto é, um ajuste como esse pode funcionar bem nos dados atuais e novos dados, enquanto na última figura o ajuste levará erros pequenos nos dados atuais mas provavelmente não funcionará bem em novos dados.




Regressão Linear Simples

- Regressão: é análise da relação entre variáveis independentes e uma variável dependente.
- Linear: Indica o uso de uma função do primeiro grau cuja representação gráfica é uma reta.
- Simples: É um modelo de simples compreensão aplicado a dados cuja dispersão é constante e nos quais temos apenas uma variável independente (a segunda variável é a dependente).
- Um diagrama de dispersão ajuda a visualizar o relacionamento.

Exemplo visual



Modelo de Regressão Linear Simples



$y_i = \alpha + \beta x_i + \varepsilon_i$ ou seja, o erro da i -ésima observação é: $\varepsilon_i = y_i - (\alpha + \beta x_i)$

O método consiste em achar α e β que minimizam $S = \sum_{i=1}^n \varepsilon_i^2$. Para isto usamos: $\frac{\partial S}{\partial \alpha} = 0$ e $\frac{\partial S}{\partial \beta} = 0$

Com isto achamos o coeficiente angular e o intercepto como sendo:


$$\beta = \frac{n \cdot \sum_{i=1}^n (x_i y_i) - (\sum_{i=1}^n x_i) \cdot (\sum_{i=1}^n y_i)}{n \cdot (\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i)^2} \text{ e } \alpha = \frac{(\sum_{i=1}^n y_i) - \beta (\sum_{i=1}^n x_i)}{n}$$

Exemplo

- A tabela abaixo mostra a colheita de algodão ao longo de cinco anos em relação à quantidade de chuva que caiu ao longo dos cinco anos em uma fazenda durante os meses que vão do plantio à colheita. Determina a provável produção para um ano cujo índice pluviométrico seja igual a 25mm.

Ano	Produção de algodão (em toneladas)	Índice pluviométrico (em mm)
2000	80	23
2001	90	27
2002	74	20
2003	104	28
2004	112	31

Solução – Diagrama de Dispersão




Solução – Ajuste da Reta

X	Y	X · Y	X ²
23	80	1.840	529
27	90	2.430	729
20	74	1.480	400
28	104	2.912	784
31	112	3.472	961
Σ = 129	460	12.134	3.403

Portanto, a reta de regressão é:

$$y = 3,556 \cdot x + 0,255$$

Gráfico da reta obtida



Previsão para índice pluviométrico igual a 25mm

$$y = 3,556 \cdot 25 + 0,255$$

$$y = 89,155 \text{ toneladas de algodão}$$

Regressão Linear Múltipla

- [https://www.w3schools.com/python/python ml multiple regression.asp](https://www.w3schools.com/python/python_ml_multiple_regression.asp)
- <https://www.analyticsvidhya.com/blog/2021/05/multiple-linear-regression-using-python-and-scikit-learn/>