

Atividade A20 - Regressão Linear Múltipla

Métodos Quantitativos – Ciência da Computação

Pontifícia Universidade Católica do Paraná

Jafte Carneiro Fagundes da Silva

21 de maio de 2026

Questão 1

Qual é a equação que representa de forma genérica uma Regressão Linear Múltipla?

A Regressão Linear Múltipla é uma extensão da Regressão Linear Simples que permite modelar a relação entre uma variável dependente Y e **duas ou mais** variáveis independentes $X_1, X_2, \dots, X_k$. Sua equação genérica é:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon \quad (1)$$

onde:

- Y – variável dependente (resposta);
- $X_1, X_2, \dots, X_k$ – variáveis independentes (preditoras);
- β_0 – intercepto (valor de Y quando todas as variáveis independentes são iguais a zero);
- $\beta_1, \beta_2, \dots, \beta_k$ – coeficientes de regressão, que representam a variação em Y para cada incremento unitário na respectiva variável X_i , mantendo as demais constantes;
- ε – termo de erro aleatório, com $\varepsilon \sim N(0, \sigma^2)$.
- k – número de variáveis independentes do modelo.

Forma matricial

Em notação matricial, a mesma equação pode ser expressa como:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (2)$$

onde $\mathbf{Y}$ é o vetor $n \times 1$ de observações, $\mathbf{X}$ é a matriz $n \times (k + 1)$ de preditoras (com a primeira coluna de 1s para o intercepto), $\boldsymbol{\beta}$ é o vetor $(k + 1) \times 1$ de coeficientes e $\boldsymbol{\varepsilon}$ é o vetor de erros.

Os coeficientes são estimados pelo método dos **Mínimos Quadrados Ordinários** (MQO):

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (3)$$

Questão 2

Crie uma situação em que se utilizaria uma Regressão Linear Múltipla:

a) Enunciado

Considere o dataset **Wine Quality**, um conjunto de dados amplamente utilizado em aprendizado de máquina que contém informações sobre 6.497 amostras de vinhos portugueses (1.599 tintos e 4.898 brancos) do tipo *Vinho Verde*.

Situação Prática:

Um enólogo deseja prever a **qualidade de um vinho** com base exclusivamente em suas **propriedades físico-químicas**, obtidas por meio de análises laboratoriais. O objetivo é desenvolver um modelo que permita:

1. Estimar a qualidade de novos lotes de vinho;
2. Identificar quais propriedades físico-químicas mais influenciam a qualidade;
3. Orientar decisões de produção e controle de qualidade.

Variáveis disponíveis:

- **Variáveis independentes (11):** acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e álcool;
- **Variável dependente (1):** qualidade (escala de 0 a 10, baseada em avaliação sensorial).

b) Dados

Os dados foram carregados do dataset *Wine Quality* do UCI Machine Learning Repository, conforme referência de Cortez et al. (2009).

Amostra: 6.497 observações com 11 variáveis físico-químicas contínuas.

Estatísticas descritivas resumidas:

Variável	Mínimo	Máximo	Média	Desvio Padrão
Qualidade	3	9	5,82	0,87
Álcool (%)	8,00	14,90	10,49	1,19
Densidade	0,987	1,039	0,995	0,003
pH	2,72	4,01	3,22	0,16
Acidez Volátil	0,08	1,58	0,34	0,16
Sulfatos	0,22	2,00	0,53	0,15

c) Passos até a Solução

Passo 1: Análise de Correlação

Primeiramente, calculou-se a matriz de correlação de Pearson entre todas as variáveis, a fim de identificar quais preditores apresentam maior relação linear com a qualidade.

Principais achados:

- **Correlação positiva mais forte:** álcool ($r = 0,444$);
- **Correlação negativa mais forte:** densidade ($r = -0,306$) e acidez volátil ($r = -0,266$);
- As demais variáveis apresentam correlações mais fracas com a qualidade.

Vide Figura 1 para visualização completa da matriz de correlação.

Passo 2: Construção do Modelo

Aplicou-se o método dos Mínimos Quadrados Ordinários (MQO) para estimar os coeficientes de regressão. O modelo foi ajustado utilizando a biblioteca `scikit-learn` do Python.

Passo 3: Estimação dos Coeficientes

Após o ajuste, obtiveram-se os seguintes coeficientes:

Variável	Coefficiente
Intercepto	+55,7627
Densidade	-54,9669
Acidez Volátil	-1,3279
Sulfatos	+0,7683
Cloretos	-0,4837
pH	+0,4393
Álcool	+0,2670
Ácido Cítrico	-0,1097
Acidez Fixa	+0,0677
Açúcar Residual	+0,0436
SO Livre	+0,0060
SO Total	-0,0025

Passo 4: Interpretação dos Coeficientes

- **Densidade:** cada aumento de 0,001 g/cm³ *reduz* a qualidade em aproximadamente 0,055 pontos;
- **Acidez Volátil:** cada aumento de 1 g/L *reduz* a qualidade em aproximadamente 1,33 pontos;
- **Sulfatos:** cada aumento de 1 g/L *aumenta* a qualidade em aproximadamente 0,77 pontos;
- **Álcool:** cada aumento de 1% *aumenta* a qualidade em aproximadamente 0,27 pontos.

d) Equação de Regressão Linear Múltipla

$$\begin{aligned} \hat{y} = & 55,7627 - 54,9669 \cdot \text{densidade} - 1,3279 \cdot \text{acidez volátil} \\ & + 0,7683 \cdot \text{sulfatos} - 0,4837 \cdot \text{cloretos} + 0,4393 \cdot \text{pH} \\ & + 0,2670 \cdot \text{álcool} + (\text{demais variáveis}) \end{aligned} \quad (4)$$

onde a notação $\hat{y}$ representa a estimativa da qualidade do vinho.

e) Medida da Qualidade da Solução – Coeficientes de Correlação

1. Coeficiente de Determinação (R^2)

O coeficiente de determinação mede a proporção da variância na variável dependente que é explicada pelos preditores:

$$R^2 = 1 - \frac{SQ_{\text{resíduo}}}{SQ_{\text{total}}} = \frac{SQ_{\text{regressão}}}{SQ_{\text{total}}} \quad (5)$$

Resultado obtido:

$$R^2 = 0,2921 \quad \Rightarrow \quad \boxed{29,21\% \text{ de variância explicada}} \quad (6)$$

Interpretação: O modelo explica aproximadamente 29% da variação total da qualidade. Embora este valor possa parecer moderado, é importante ressaltar que:

- A qualidade é um julgamento sensorial subjetivo, sujeito a variabilidade inerente;
- Apenas propriedades físico-químicas foram consideradas; fatores como uva utilizada, técnicas de fermentação e aging não estão disponíveis;
- Um R^2 de 0,29 ainda representa um poder preditivo relevante.

2. Coeficiente de Determinação Ajustado (R^2_{ajustado})

O R^2 ajustado penaliza a adição de variáveis que não contribuem significativamente ao modelo:

$$R^2_{\text{ajustado}} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1} \quad (7)$$

onde $n = 6.497$ observações e $p = 11$ preditores.

Resultado obtido:

$$R^2_{\text{ajustado}} = 0,2909 \Rightarrow \boxed{29,09\%} \quad (8)$$

Interpretação: O R^2 ajustado é muito próximo ao R^2 não-ajustado (diferença de 0,12 p.p.), sugerindo que a inclusão das 11 variáveis é adequada e não há sobreajuste.

3. Correlação de Pearson entre Valores Reais e Preditos

A correlação de Pearson entre os valores observados e os valores preditos pelo modelo avalia a força da relação linear:

$$r = \sqrt{R^2} = \sqrt{0,2921} = 0,5405 \quad (9)$$

Resultado e Interpretação:

- $r = 0,5405$ (correlação moderada a forte);
- p-valor $< 0,001$ (altamente significativa);
- O modelo produz previsões que correlacionam fortemente com os valores reais.

4. Raiz do Erro Quadrático Médio (RMSE)

O RMSE mede o desvio médio das previsões em relação aos valores reais:

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (10)$$

Resultado obtido:

$$\text{RMSE} = 0,7347 \quad (11)$$

Interpretação: Em média, as previsões do modelo desviam $\pm 0,73$ pontos da escala de qualidade (que varia de 3 a 9). Considerando que a escala é relativamente curta, este erro é moderado.

5. Erro Absoluto Médio (MAE)

O MAE representa o erro absoluto médio sem considerar a direção do erro:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (12)$$

Resultado obtido:

$$\text{MAE} = 0,5683 \quad (13)$$

Interpretação: Em média, as predições diferem $\pm 0,57$ pontos dos valores reais.

6. Análise de Variância (ANOVA)

A decomposição da variância total permite avaliar o modelo como um todo:

Fonte	Soma Quadrados	G.L.	Quadrado Médio
Regressão	1.447,15	11	131,56
Resíduo	3.506,53	6.485	0,54
Total	4.953,69	6.496	

O teste F resulta em:

$$F = \frac{\text{QM}_{\text{regressão}}}{\text{QM}_{\text{resíduo}}} \approx 243,26, \quad p\text{-valor} < 0,001 \quad (14)$$

Conclusão: O modelo como um todo é altamente significativo. Rejeita-se a hipótese nula de que todos os coeficientes são iguais a zero.

7. Validação das Suposições

As suposições clássicas do modelo de regressão linear foram verificadas:

- **Linearidade:** Verificada através da Figura 2 (reais vs preditos);
- **Normalidade dos resíduos:** Q-Q Plot na Figura 3 mostra aproximação à distribuição normal;
- **Homocedasticidade:** Gráfico de resíduos vs preditos (Figura 4) não evidencia padrão sistemático;
- **Independência:** Resíduos não apresentam autocorrelação visível.

Resumo Sintético das Métricas

Métrica	Valor	Interpretação
R^2	0,2921	29,21% da variância explicada
R^2_{ajustado}	0,2909	29,09% (ajustado por p)
r (Pearson)	0,5405	Correlação moderada-forte
RMSE	0,7347	Desvio médio $\pm 0,73$ pontos
MAE	0,5683	Erro absoluto médio
F-estatístico	243,26	Modelo muito significativo
p-valor (F)	$< 0,001$	Altamente significativo

Conclusão Final

O modelo de Regressão Linear Múltipla apresenta qualidade adequada para prever a qualidade de vinhos com base em suas propriedades físico-químicas. Embora o R^2 de 0,29 indique que apenas 29% da variação é explicada pelos preditores, este resultado é coerente com a natureza subjetiva da avaliação sensorial de qualidade. O modelo é estatisticamente significativo e as predições correlacionam-se fortemente com os valores reais ($r = 0,54$).

A utilização de múltiplos coeficientes de correlação — R^2 , R^2_{ajustado} , r de Pearson, RMSE e testes estatísticos — permite uma avaliação multifacetada e robusta da qualidade da solução, confirmando que a Regressão Linear Múltipla é um método apropriado para este problema.