

Pontifícia Universidade Católica do Paraná
Escola Politécnica
Bacharelado em Ciência da Computação

Regressão Linear Múltipla

Aplicada à base Wine Quality

Aluno: Jafte Carneiro Fagundes da Silva

Disciplina: Métodos Quantitativos em Computação

Professor: Júlio Cesar Nievola

Turma: Turma U

Período: 2026/01

Curitiba
2026

Resumo

Este trabalho aplica Regressão Linear Múltipla a uma base de dados numérica. A base utilizada foi `wine_quality_original.csv`. O objetivo é prever uma variável dependente a partir de duas variáveis independentes escolhidas por maior correlação absoluta com a variável que se deseja prever. A variável dependente escolhida foi `quality`; as variáveis explicativas selecionadas foram `alcohol` e `density`. O modelo obteve $R^2 = 0.1974$.

Sumário

Resumo	1
Introdução	3
1. Variáveis presentes na base	3
2. Variável dependente escolhida	3
3. Correlação entre variáveis independentes e dependente	3
4. Obtenção da equação de Regressão Linear Múltipla	4
5. Avaliação da qualidade das previsões	5
Gráficos	6
Conclusão	8

Introdução

Este trabalho aplica Regressão Linear Múltipla a uma base de dados numérica. A base utilizada foi `wine_quality_original.csv`. O objetivo é prever uma variável dependente a partir de duas variáveis independentes escolhidas por maior correlação absoluta com a variável que se deseja prever.

As seguintes colunas não numéricas foram ignoradas: `wine_type`.

1. Variáveis presentes na base

A tabela a seguir apresenta as variáveis numéricas identificadas na base.

Variável	Tipo	Válidos	Média	Desvio	Mínimo	Máximo
fixed acidity	float64	6497	7.2153	1.2964	3.8000	15.9000
volatile acidity	float64	6497	0.3397	0.1646	0.0800	1.5800
citric acid	float64	6497	0.3186	0.1453	0.0000	1.6600
residual sugar	float64	6497	5.4432	4.7578	0.6000	65.8000
chlorides	float64	6497	0.0560	0.0350	0.0090	0.6110
free sulfur dioxide	float64	6497	30.5253	17.7494	1.0000	289.0000
total sulfur dioxide	float64	6497	115.7446	56.5219	6.0000	440.0000
density	float64	6497	0.9947	0.0030	0.9871	1.0390
pH	float64	6497	3.2185	0.1608	2.7200	4.0100
sulphates	float64	6497	0.5313	0.1488	0.2200	2.0000
alcohol	float64	6497	10.4918	1.1927	8.0000	14.9000
quality	int64	6497	5.8184	0.8733	3.0000	9.0000

2. Variável dependente escolhida

A variável dependente escolhida foi *quality*. A variável dependente foi escolhida automaticamente por ser a última coluna numérica da base.

Essa variável será prevista a partir das demais variáveis numéricas presentes na base.

3. Correlação entre variáveis independentes e dependente

Foi calculado o coeficiente de correlação de Pearson¹ entre cada variável independente e *quality*. A interpretação adotada foi: próxima de 0, correlação fraca; entre 0,3 e 0,7, correlação moderada; acima de 0,7, correlação forte.

Variável independente	Correlação	Absoluta	Interpretação
alcohol	0.4443	0.4443	moderada

¹Foi usado o coeficiente de Pearson por ser a medida de correlação linear mais comum em aplicações de Regressão Linear quando as variáveis analisadas são numéricas.

density	-0.3059	0.3059	moderada
volatile acidity	-0.2657	0.2657	fraca
chlorides	-0.2007	0.2007	fraca
citric acid	0.0855	0.0855	fraca
fixed acidity	-0.0767	0.0767	fraca
free sulfur dioxide	0.0555	0.0555	fraca
total sulfur dioxide	-0.0414	0.0414	fraca
sulphates	0.0385	0.0385	fraca
residual sugar	-0.0370	0.0370	fraca
pH	0.0195	0.0195	fraca

As duas variáveis independentes escolhidas foram:

- $x_1 = \text{alcohol}$
- $x_2 = \text{density}$

Elas foram escolhidas por apresentarem maior associação linear absoluta com a variável dependente.

4. Obtenção da equação de Regressão Linear Múltipla

A forma geral da Regressão Linear Múltipla com duas variáveis explicativas é:

$$y = b_0 + b_1x_1 + b_2x_2$$

Nessa equação, y representa a variável dependente; x_1 e x_2 representam as variáveis independentes; b_0 representa o intercepto; e b_1 e b_2 representam os coeficientes angulares.

Neste trabalho:

```
y = quality
x1 = alcohol
x2 = density
```

A matriz de entrada X foi formada pelas duas colunas *alcohol* e *density*. O vetor y foi formado pela coluna *quality*. O método de mínimos quadrados procura os coeficientes que minimizam a soma dos quadrados das diferenças entre os valores reais e os valores previstos.

A organização matricial usada na regressão vem diretamente da base de dados. Cada linha da matriz X representa uma observação da base, isto é, um vinho analisado. Cada coluna de X representa uma variável independente escolhida para o modelo. Como foram selecionadas duas variáveis explicativas, a matriz X contém os valores de *alcohol* e *density*. O vetor y ,

por sua vez, contém os valores reais da variável dependente *quality*, na mesma ordem das observações de *X*.

O vetor de coeficientes β reúne os valores que o modelo precisa estimar. Neste caso, ele contém o intercepto b_0 , o coeficiente b_1 associado a *alcohol* e o coeficiente b_2 associado a *density*. Na prática, a regressão procura os valores de β que fazem as previsões ficarem o mais próximas possível dos valores reais de y .

Na expressão matricial, X^T é a transposta da matriz X , usada para combinar as informações das observações e das variáveis. O termo $(X^T X)^{-1}$ representa a inversa da matriz $X^T X$, quando essa inversa existe. Essa forma é a solução clássica dos mínimos quadrados para estimar os coeficientes da regressão linear.

A fórmula conceitual dos coeficientes é:

$$\beta = (X^T X)^{-1} X^T y$$

Assim, a fórmula mostra que os coeficientes são calculados a partir da matriz das variáveis independentes e do vetor da variável dependente.

Os coeficientes calculados foram:

- $b_0 = 2.8095$
- $b_1 = 0.3246$
- $b_2 = -0.3991$

A equação final encontrada foi:

$$\text{quality} = 2.8095 + 0.3246 \cdot \text{alcohol} - 0.3991 \cdot \text{density}$$

5. Avaliação da qualidade das previsões

O principal coeficiente de qualidade usado foi o coeficiente de determinação R^2 . Ele indica quanto da variação da variável dependente é explicada pelo modelo.

O valor encontrado foi:

$$R^2 = 0.1974$$

Isso significa que aproximadamente 19.74% da variação da variável dependente *quality* é explicada pelas duas variáveis independentes escolhidas. Como o R^2 está mais próximo de 0 do que de 1, o modelo apresenta qualidade baixa de explicação.

Também foram calculadas medidas auxiliares²:

²A inclusão de MAE e RMSE é opcional nesta atividade. O aluno optou por apresentá-las como complemento ao coeficiente de determinação R^2 , pois essas métricas indicam o tamanho médio do erro das previsões. A avaliação principal do modelo, entretanto, permanece baseada no R^2 , conforme solicitado no enunciado.

- $MAE = 0.6188$
- $RMSE = 0.7823$

Gráficos




Figura 1: Valores reais versus valores previstos pelo modelo de regressão.




Figura 2: Distribuição dos resíduos em função dos valores previstos.

Interpretação dos gráficos

O gráfico de valores reais versus valores previstos compara a nota real de qualidade do vinho com a nota estimada pelo modelo de Regressão Linear Múltipla. No eixo horizontal estão os valores reais de *quality*, enquanto no eixo vertical estão os valores previstos pelo modelo. Em um modelo com alta precisão, os pontos tenderiam a ficar próximos de uma linha diagonal, indicando proximidade entre os valores reais e previstos. No entanto, observa-se que as previsões ficam concentradas em uma faixa mais estreita, próxima das notas intermediárias. Isso indica que o modelo tende a prever valores médios e apresenta maior dificuldade para representar notas muito baixas ou muito altas.

O gráfico de resíduos apresenta a diferença entre o valor real e o valor previsto pelo modelo, isto é:

$$resduo = y - \hat{y}$$

A linha horizontal em zero representa a situação em que não há erro de previsão. Em um modelo ideal, os resíduos deveriam estar distribuídos de forma aleatória ao redor dessa linha, sem formação de padrão evidente. No gráfico gerado, os resíduos aparecem em faixas, pois a variável *quality* é uma nota inteira, enquanto a regressão produz valores previstos contínuos. Além disso, há resíduos positivos e negativos, mostrando que o modelo ora subestima, ora superestima a qualidade.

Assim, os gráficos confirmam que o modelo apresenta capacidade limitada de previsão.

Essa interpretação é coerente com o valor de $R^2 = 0.1974$, indicando que *alcohol* e *density*, embora sejam as variáveis mais correlacionadas com *quality*, não explicam sozinhas a maior parte da variação da qualidade dos vinhos.

Conclusão

Neste trabalho, a variável prevista foi *quality*. As variáveis independentes usadas no modelo final foram *alcohol* e *density*. A equação encontrada foi $quality = 2.8095 + 0.3246*alcohol - 0.3991*density$. O coeficiente de determinação foi $R^2 = 0.1974$, indicando qualidade baixa para as previsões quando se usam apenas essas duas variáveis explicativas.